

COSMO：亚马逊大规模电子商务常识知识生成和服务系统

于长龙^{1,2♣}、刘鑫^{1,2♣}、Jefferson Maia¹、曹天宇¹、李阳¹、高一凡¹、宋阳秋^{1,2}、Rahul Goutam¹、张海洋¹、丙寅¹、郑力^{1♣*}

♣ 核心贡献者。通讯作者：郑莉。

¹Amazon.com Inc, 美国帕洛阿尔托²中国香港特别行政区香港科技大学
{昌留, xliucr, jdmaia, caoty, limyng, 一芳高, gyangqiu}@amazon.com
{rgoutam, hhaiz, alexbyin, amzzhe}@amazon.com

摘要

大规模知识图谱（KG）在电子商务平台中的应用可以改善客户的购物体验。现有的电商知识图谱虽然集成了大量的概念或产品属性，但无法发现用户的意图，与人们的思维、行为以及与周围世界的互动方式存在差距。在这项工作中，我们提出了COSMO，这是一个可扩展的系统，可以从海量行为中挖掘以用户为中心的常识知识，并构建行业规模的知识图谱来赋能多样化的在线服务。特别是，我们描述了一个用于收集高质量种子知识断言的管道，这些断言是从大型语言模型（LLM）中提取出来的，并由在人机循环注释数据上训练的批评分类器进一步细化。由于这些代可能并不总是符合人类偏好并包含噪音，因此我们随后描述了如何采用指令调整来微调高效语言模型

（COSMO-LM），以大规模地生成忠实的电子商务常识知识。COSMO-LM 有效地将我们的知识图谱扩展到亚马逊的 18 个主要类别，仅用 3 万条带注释的指令就产生了数百万条高质量知识。最后，COSMO 已部署在各种亚马逊搜索应用程序中，包括搜索相关性、基于会话的推荐和搜索导航。离线和在线 A/B 实验都表明我们提出的系统取得了显著的改进。此外，这些实验凸显了从指令微调大型语言模型中提取常识知识的巨大潜力。

CCS 概念

· 大型语言模型、知识库；

1 介绍

了解在线电子商务平台中大量噪音行为背后的用户意图对于许多下游应用程序（例如推荐和产品搜索等）有益[9, 16]。从认知科学的角度来看，意图是人类致力于行动的心理状态，行为是意图的结果[27]。例如，“参加婚礼，我们需要购买普通衣服”，其中意图“参加婚礼”用于合理化和解释用户行为，即“购买普通衣服”。在网上购物时

*该项目的研究是Changlong和Xin在亚马逊实习期间进行的。宋扬秋教授是亚马逊访问学者。



图1：从电子商务用户行为中挖掘隐含常识知识的示例。

在这些场景中，如果电子商务平台能够准确捕捉用户的意图，那么它们可以更加智能和人性化，提供可解释的推荐和个性化的搜索体验。然而，人类并没有明确表达这些意图，这需要常识才能理解，因此机器以可扩展的方式提取具有挑战性。

最近，Yu 等人。[45]建议利用GPT3 [2]或OPT [48]等大型语言模型中隐式存储的大量知识，并通过“询问”用户购买或共同购买产品的原因来生成用户意图。如图1所示，可以从用户行为中发现电商常识知识。然后，人机交互注释将参与收集判断并提供自动生成的人类反馈。在大规模注释数据上训练的分类器用于过滤低质量的知识。这种蒸馏方法已被证明可以有效地以较低的注释成本提取高精度常识知识[41, 45]。然而，这些方法从语言模型生成的候选知识与人类偏好不太相符。例如，我们观察到法学硕士可以产生既不忠实又无帮助的通用意图，例如“客户因为喜欢而一起购买了它们”或“客户购买了一个

表1: 现有常识知识图谱对比。“Rel”代表关系类型。与现有的电子商务相关的 KG 相比, 我们的新 KG 涵盖了更多领域的更多节点和边缘, 用于意图理解。

千克	# 节点	# 边缘	# 相关数	来源	节点类型	电子商务	意图	用户行为
概念网[30]	8M	21M	36	众包 ¹	概念		X√X	
原子 [25]	300K	870K	9	众包	日常情况、事件		X√X	
阿里可可 [13, 14]	163K	813K	91	萃取	概念	√X		搜索日志
阿里CG [47]	5M	13.5M	1	萃取	概念、实体	XX		搜索日志
民谣范围 [45]	1.2M	12M	19	法学硕士一代	产品、意图	2 个域名	✓	共同购买
COSMO (我们的)	6.3M	29M	15	法学硕士一代	产品、查询、意向	18 个域名	✓	共同购买&搜索购买

Apple Watch 因为它是手表的一种”。期望的一代应该是解释电子商务行为的典型。让语言模型更好地遵循用户的指令对于提高法学硕士的有用性 [1, 18]、真实性 [15] 和透明度 [26] 至关重要。

另一方面, 这种蒸馏方法仍然面临着工业级数据的可扩展性问题带来的重大挑战。首先, [45]仅基于两个类别内的数千个共同购买项目对来探索共同购买意图。在真实的生产环境中, 数以百万计的用户每天都会产生复杂而嘈杂的行为, 这也可能蕴含着巨大且多样化的意图, 例如搜索购买行为。因此, 为不同的意图生成选择代表性的用户行为至关重要。其次, [45]通过单独标记合理性和典型性分数来执行细粒度注释。随着我们的目标是全面支持更多的电子商务场景, 随着类别的增加和用户行为类型的增加, 标注成本显着增加。第三, 当将 FolkScope 应用于下游任务时, 推理开销可能会成为瓶颈, 因为新用户行为的知识生成必须经过 LLM 生成和分类器评分的流程。像 FolkScope 中使用的 OPT-30b 这样的 LLM 需要巨大的计算成本, 并且不适合在线服务。

在这项工作中, 受指令遵循语言模型 [4,24,38,40] 最新进展的推动, 我们通过电子商务常识知识提取的指令调整, 直接将语言模型与人类反馈保持一致。在大量数据集上进行指令微调的语言模型已经表现出了卓越的零样本能力[40]。如何收集高质量、多样化的教学数据变得重要且具有挑战性。从[45]中跨两个共同购买行为领域的注释数据开始, 我们在意图知识资源 (即用户行为)、产品领域和关系类型方面扩大了数据收集, 如图4所示。行为方面, 我们还采用行业规模的查询项交互来生成模糊且不断变化的意图。与共同购买行为背后的直接意图不同[45], 查询意图可以帮助减少用户真正需要的内容与产品信息在电子商务系统中的呈现方式之间的语义差距。生成的意图可以帮助将广泛的查询细化为特定用户的需求, 并提高查询理解能力。此外, 我们还对 18 个热门领域 (产品类别) 中的数百万个两个用户行为数据进行了采样, 以生成候选知识 (第 3.2 节)。在进行人工标记之前, 我们创建了一个启发式规则分支来过滤掉低质量的知识, 并为带注释的数据选择设计仔细

的采样策略 (§3.3)。跟随 Yu 等人。 [45], 我们收集了两个名为合理性和典型性的评估指标作为人类反馈 (§3.3.2)。为了将语言模型与人类判断融合起来, 我们选择典型的知识示例作为常识生成任务所需模型输出的演示, 同时注释标签作为标签预测任务 (例如典型性预测等) 所需的模型输出 (§3.4)。由此产生的 LM 能够生成典型知识并判断知识质量。与普通的 LLM 相比, 我们的指令微调 LM 可以显着减少推理时间并支持大规模的广泛应用。我们成功地将 COSMO 部署在各种亚马逊搜索应用程序中, 并实现了离线性能的显着提升和在线收入的增加。

我们的工作贡献可总结如下。

- 我们是第一个采用大语言模型构建高质量知识图谱并服务在线应用的行业规模知识系统。
- 我们采用指令调整来生成有效的电子商务常识知识, 以更好地符合人类偏好。
- 我们将电子商务意图知识扩展到数百万用户行为, 并以更少的注释工作实现高质量的指令数据生成。
- 我们将生成的意图知识应用于三个现实世界的电子商务任务, 并且有希望的实验结果显示了更多电子商务场景的巨大潜力。

2 相关工作

电子商务常识。现有的电子商务知识图谱[5,8,13,14,46,47]主要基于isA或authorOf关系等有关产品属性的事实知识, 与“苹果产品”等有关用户意图的常识性知识没有很好的联系收集产品的事实知识和建模用户的购买意图之间仍然存在差距, 我们在表1中列出了详细的比较。相比之下, Yu等人。 [45]提出了一个名为 FolkScope 的框架, 通过提示大型语言模型从大量用户行为中提取意图知识。人类并不直接创作知识断言, 而是仅将少量自动生成标记为高级监督。然后使用经过标记数据训练的分类器来过滤掉低质量的一代。尽管FolkScope以较低的标注成本实现了高精度提取, 但它覆盖的领域有限, 忽略了丰富类型的用户交互数据

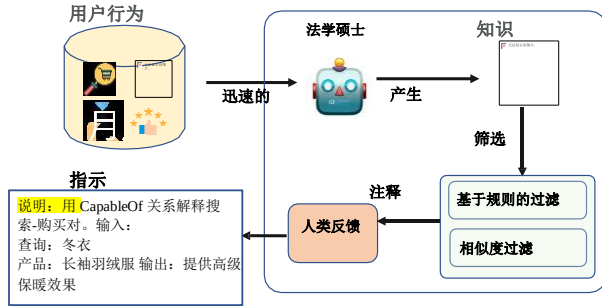


图2：从海量用户行为和大量语言模型生成高质量指令数据的总体框架。

这需要电子商务场景中复杂的意图知识。为了提高电子商务常识提取的泛化性，我们扩展了 FolkScope，包括扩展到 18 个热门领域并引入数百万搜索查询行为数据。从法学硕士中提取知识时，扩大规模还带来了推理效率方面的挑战。我们通过有效的微调来解决它们。

指令遵循的语言模型。在网络规模的语料库上预训练的语言模型通常会生成不忠实、有偏见或无益的上下文。这是因为大多数普通 LM 的训练目标（即预测下一个标记）与人类偏好不一致。最近的一系列工作表明，使用自然语言指令微调语言模型可以教会 LM 具有所需的模型行为 [18, 40]。经过指令微调的 LM 显著提高了其在未见过的任务上的零样本和少样本性能 [4,24,38]。指令数据的质量和多样性对 LM 的指令跟踪能力有很大影响。由于收集人类书面指令既耗时又昂贵，Wang 等人 [37] 提出了基于小型种子任务集的自指令，以迭代方式从 GPT3 [2] 生成指令及其输出。后续工作 [3,19,32] 直接使用来自 ChatGPT 或 GPT4 的机器生成的指令跟踪数据进行 LLM 微调。然而，他们更关注通用语言模型，而针对电子商务等特定领域的指令微调语言模型仍未得到探索。我们的工作旨在高效地收集电子商务教学数据并微调法学硕士，以生成有用且典型的常识知识。上述 KG 均与产品或购买意向无关。我们是第一个从法学硕士和海量用户意图行为中提出有效的知识图谱构建管道的人。我们的管道可以高效地在线服务行业规模的应用程序。

3 拟议框架

3.1 初步的

在本节中，我们将介绍图 2 中术语的正式定义以及离线 COSMO 知识生成管道的概述。用户行为。每天有数百万用户与在线电商平台交互，产生海量的行为日志。电子商务系统挖掘这些行为背后的意图，以提供更好的在线购物体验。我们选

择两种具有强烈潜在意图的典型用户行为，即搜索购买和共同购买。正式地，我们将搜索-购买行为定义为查询-产品对 (q, p) ，即客户点击查询 q 并最终在短时间内购买产品 p 。类似地，我们使用共同购买的产品对 (p_1, p_2) 来表示共同购买行为。每个产品 p 都可以分为一个主要领域 $d \in D$ （所有领域如表 3 和图 4 所示）。

常识性知识。按照 [45]，我们利用法学硕士的关系感知提示将用户行为 h 解释为知识候选，我们将知识表示为三元组 (h, r, t) ，其中 r 和 t 分别代表关系和尾部。例如，“客户将相机壳和屏幕保护玻璃一起购买，因为它们能够为相机提供保护”，“为相机提供保护”是关系下的尾部

有能力的。与之前的工作 [45] 针对数千个数据对齐 ConceptNet [30] 中的常识关系不同，由于计算限制，我们不能简单地采用数百万个用户行为对。因此，我们提出大规模生成的数据驱动的关系发现来满足电子商务场景。基本思想是从四种种子关系（即 `usedFor`、`capableOf`、`isA`、`cause`）开始，根据之前的工作 [45]，这些种子关系往往会生成多样化/高质量的知识，并挖掘频繁的谓词模式来手动总结关系。最常见的模式是“该产品能够被使用 [Prep]”，其中 [Prep] 表示介词。不同介词的世代代表不同的尾部类型，可以进一步规范化。通过这样做，我们还可以使生成的知识结构化。我们总结了我们的挖掘的知识关系类型和相应的尾部类型以及表 2 中的示例。无论是关系类型还是尾部类型都更具有电子商务特定性，并且与日常场景密切相关，这可能需要常识。

指令数据。我们将 $\{It\}$ 表示为一组指令，每个指令用自然语言定义一个任务 t 。图 2 中的一个示例是“使用 `CapableOf` 关系生成领域 d 中的搜索购买行为的解释”。每个任务都包含 It 输入输出对实例。对于常识生成任务，输入可以是用户行为对 (p_1, p_2) 或 (q, p) ，输出是典型的知识尾 t 。请注意，知识的质量 (h, r, t) 可以通过人类注释者标记的合理性和典型性分数来衡量 [20, 45]。出于可用性和帮助性的考虑，我们选择具有高典型性分数的知识作为所需的模型输出。为了进一步提高指令微调模型的电子商务感知能力，我们还添加了一些辅助任务并训练了用于知识泛化和在线服务的语言模型（更多详细信息参见 §3.4）

3.2 知识生成

在本节中，我们首先描述如何有效地采样代表性用户行为作为法学硕士的输入。然后我们引入基于问答的提示，从普通法学硕士中收获大规模知识候选人。

3.2.1 用户行为采样。每天有数百万用户与在线电商平台互动并产生海量行为

表 2：挖掘的电子商务常识关系
科斯莫两合公司。

关系类型	尾型	例子
用于函数	功能/用途	前夕使用
干脸	事件/活动	遛狗
used_for_aud	观众	日托工作者有
能力	功能/用途	持有零食习
惯	功能/用途	建一个围栏
used_as	概念/产品类型	智能手表
is_a	概念/产品类型	普通套装
used_on	时间/季节/活动	冬末
used_in_loc	地点/设施	卧室在身
体中使用	身体部位	敏感皮肤使
用过	补充	表面覆盖物
使用者	观众	猫主人
xInterested_in	兴趣	草药
xIs_a	观众	孕妇
想要	活动	打网球

日志。电子商务系统挖掘这些行为背后的意图，以提供更好的在线购物体验。

在我们的工作中，我们选择了两种具有强烈潜在意图的典型用户行为，即搜索购买和共同购买，如

§3.1。大音量行为包含噪音或无意随机的。为了产生多样化、高质量的知识边缘，我们进行细粒度采样，从产品采样开始，然后是行为对采样。对于产品采样，我们覆盖了亚马逊最常见的热门类别（也称为浏览节点²），并选择了行为交互较大的顶级产品。除了类别标签外，我们还采用产品类型标签进行抽样，定义了一千多个类别并描述了产品的本质，例如雨伞、椅子等。

对于共同购买对抽样，每个共同购买边缘应至少覆盖所选产品集中的一个，并且我们与抽样对的产品类型进行交叉检查，以消除随机共同购买并避免从抽象级别重复抽样。还应用一些启发式规则，例如不同类型的产品共同购买的产品可能是随机选择的。对于搜索-购买对抽样，我们根据经验设置购买率和点击率的阈值，以对查询和购买的产品进行抽样。一个关键的考虑因素是查询的特殊性，它表明查询是广泛的还是特定的。由于我们的目标是弥补搜索查询和产品之间的语义差距，因此为广泛或模糊的查询生成知识对于缩小明确的需求更有价值。因此，我们使用亚马逊搜索的一项内部服务来计算查询的特异性得分，并采样与购买的产品相关的广泛查询。对于大多数具有高参与度的搜索查询，搜索引擎可以很好地理解他们的意图。我们还对参与度较低和购买率较低的查询进行抽样，以直接探测来自法学硕士本身的知识。采取以上所有策略

²<https://www.browsenodes.com/>

考虑到这一点，我们最终对数百万个行为对进行了采样。抽样行为对的统计如表3所示，314万个共购产品对中在140万个产品类型对，这也体现了我们抽样的多样性。

3.2.2 QA 提示生成。法学硕士已被证明可以在其参数中编码大量知识。专门设计的提示可以使自回归法学硕士能够在口头提示的情况下继续生成。例如，给定一个购买行为“客户购买了 iPhone，因为它有”，LLM 可以生成与“iPhone”的功能或属性相关的意图知识。在我们的工作中，我们发现法学硕士在给出与特定用户行为一致的详细描述的场景或任务说明的情况下更擅长回答情境化问题。因此，我们通过提供问答 (QA) 上下文来表达用户行为。以图 3 中的以下搜索-购买提示为例。

任务：请对以下搜索购买行为提供典型解释并完成答案。

搜索查询：{查询}

产品：{产品标题}

问题：该产品的功能是什么，与搜索查询的意图完全匹配？

答：该查询表示客户想要具有以下功能的产品

1.

图 3：用于生成候选知识的提示。

在末尾添加数字字符“1”是生成候选知识列表的有用的提示工程技巧。我们首先提供任务描述，例如“以下搜索查询导致以下产品购买”，然后遵循具体查询和产品信息。对于一般的 LLM，我们附加一个问题和部分答案，以便 LLM 可以遵循给定的说明，方便解析生成。在我们的工作中，我们使用托管在 16 个 A100 GPU 上的 OPT175b 和 OPT30b [48] 来进行生成推理³。附录表 9 显示了每个域的一些生成示例。

3.3 知识提炼

尽管精心设计的知识生成和特定于关系的解析，普通法学硕士可以生成通用或不忠实知识。为了鼓励多样性和乐于助人，我们使用以下步骤来筛选世代。

³由于隐私数据，我们不选择查询强大的 ChatGPT 或 GPT4 API 访问和隐私限制。

表3: COSMO知识图谱的统计, 包括采样的用户行为对、带注释的候选知识以及知识细化后的剩余边。

类别	共同购买			搜索-购买		
	# 行为对	# 注释	# 边缘	# 行为对	# 注释	# 边缘
服装、鞋子和珠宝	233,989	1303	2,147,605	176,018	597	887,130
运动与户外	251,713	1302	2,140,491	126,130	970	556,233
家居及厨房	426,070	1991	3,380,502	225,377	3798	1,054,764
庭院、草坪和花园	117,871	542	908,158	56,754	263	280,932
工具和家居装修	258,480	1184	1,988,346	122,613	585	629,004
乐器	24,206	84	174,238	9,385	24	33,786
工业与科学	385,990	1820	3,002,352	177,400	1317	814,266
汽车	166,234	782	1,330,580	55,201	456	258,340
电子产品	178,938	777	1,316,937	119,764	768	549,716
婴儿用品	111,204	430	721,727	30,156	38	135,702
艺术、工艺品和缝纫	13,1131	616	1,095,531	62,135	232	274,015
健康与家居	233,945	1198	1,906,447	215,349	67	930,307
玩具和游戏	148,455	646	1,165,692	73,512	536	291,107
电子游戏	16,436	60	106,449	10,306	30	29,681
杂货和美食	99,660	504	775,016	116,765	2123	577,986
办公用品	136,519	650	1,086,735	79,470	2063	364,767
宠物用品	43,541	206	302,839	51,807	1122	219,143
其他的	182,738	905	1,351,257	160,189	11	648,765
全部的	3,147,120	15,000	24,900,902	1,868,331	15,000	5,093,795

3.3.1 粗粒度过滤。在此步骤中, 我们的目标是借助适用于任何行为的语言分析和常识来过滤不完整的世代。

基于规则的过滤。我们首先使用 `nltk` 的句子分割工具从生成中提取第一个句子。然后我们基于GPT-2语言模型计算困惑度分数并调整阈值以删除不完整的句子。我们还直接过滤与查询、产品类型或产品标题完全相同 (或编辑距离小于阈值) 的代。

对于“出于相同原因使用”或“与衣服一起使用”等一般知识, 我们通过结合频率和熵来识别这些情况, 因为它们与许多产品或查询而不是特定产品或查询同时出现。

相似性过滤。为了处理最后一步中不易处理的语义相似情况, 我们使用内部语言模型, 该模型在电子商务语料库上进行了预训练, 包括查询、产品信息等, 以获得通用的嵌入。吃知识尾巴, 自己查询和产品。知识嵌入和上下文嵌入 (原始查询或产品嵌入) 之间的相似度通过它们的余弦相似度计算:

$$d(k, c) = \cos(E(k), E(c)).$$

1)

我们发现过滤后的生成本质上是通过语法转换对原始用户行为上下文进行的释义。通过两个粗粒度的过滤步骤, 我们能够去除相当大量的噪声并尽可能保留典型知识。

馈并收集不同的指导数据。最大的挑战仍然是海量知识候选与成本之间的平衡。我们期望在带注释的数据上训练的模型能够在表 3 所示的多个类别中很好地泛化。均匀采样可能会损害长尾知识的预测性能。相反, 我们结合产品或查询的知识频率和流行度的日志来重新加权:

$$w(q,p),t = \frac{\text{日志}(f(t))}{\text{pop}(q) \times \text{pop}(p)},$$

(2)

其中 $f(t)$ 是生成知识的频率, 流行度函数由查询产品交互图中的查询程度或产品共同购买图中的产品程度定义。产品越受欢迎, 生成的知识就越有可能是通用的。对于这两种用户行为, 我们抽取了 15000 个候选知识进行注释, 分布也如表 3 所示。

由于数据隐私问题, 我们聘请专业的数据标注供应商公司进行高质量的标注, 并进行严格仔细的内部审核流程。之前的工作[45]通过两步注释来衡量生成知识的质量, 即合理性 (知识如何合理) 和典型性 (知识对于典型购物行为的代表性)。一个例子是, 顾客购买苹果手表更典型的意图是, 它是一款智能手表, 而不是用来报时的。为了减少注释者的认知负担和常识的潜在分歧率, 我们将两种测量的判断分解为五个明确的问题: 1)。解释是一个完整的句子吗? 2)。解释相关吗? 3)。解释内容是否丰富? 4)。

3.3.2 人机交互注释。注释步骤旨在为候选知识提供人类反



图 4：微调 COSMO-LM 以根据两种典型用户行为生成电子常识知识的图示。我们扩大产品领域、关系类型和任务。

这个解释可信吗？ 5)。解释是否典型？，其中每个问题由两个不同的注释者标记为是/否/不确定，最后由第三人检查是否发现分歧⁴。超过 2000 个示例注释的试点研究表明，该管道显着降低了分歧率。对于标注数据的质量，我们随机抽取5%的标注进行内部审核，准确率可以达到90%以上。然后，我们使用这些数据构建分类模型，在粗粒度过滤后对所有候选知识进行评分。我们对 DeBERTa-large [6] 和我们的内部语言模型进行了微调，以将人类的判断填充到剩下的合理性得分高于 0.5 的整个知识候选者中。经过知识提炼的过程，我们以相对较低的成本获得了高质量的电子商务知识，统计数据也如表3所示。

3.4 指令调整的 COSMO 语言模型

3.5 在收集了人类对 30k 个不同知识样本的判断后，我们可以基于注释数据创建大规模的指令数据。标注结果如表4所示。我们可以观察到超过三分之一的搜索-购买代是典型的，可以直接作为指令数据。但共同购买的典型比例明显较低，因为法学硕士大多生成共同购买产品之一的意图知识，而不是考虑其共同原因，这使得几代人都难以置信。我们期望微调的语言模型具有所需的模型行为。除了生成典型知识之外，我们还使 LM 具备能力

⁴每个问题的说明详见附录B和截图
注释接口如图11所示。

表 4：两种用户行为的注释数据的合理性和典型性比率。

	合理性	典型性
搜索-购买	44.3%	35.0%
共同购买	14.5%	9.0%




图 5：COSMO-LM 部署图示，以异步缓存存储和功能存储作为中心组件。它描述了用户查询和动态每日更新的高效处理，这对于满足亚马逊的搜索延迟要求至关重要。

合理性和典型性预测，其中所有注释都转换为任务的指令数据。

考虑到用户行为数据的不可忽略的噪声，我们在第 3.3.2 节中的细粒度注释已经识别出不相关的查询产品对或随机购买对。我们还考虑将共同购买预测和搜索相关性预测添加到微调任务中。到目前为止，我们收集了涵盖 18 个产品领域、15 种关系类型和 5 种不同类型任务的指令数据。为了使模型对不同的格式具有鲁棒性，我们设计了不同的模板来表达指令和输入输出对。例如，我们添加“搜索查询”、“用户输入”或“用户搜索：”等前缀。我们使用收集的指令数据对广泛使用的开放基础模型 LLaMA 7b 和 13b 模型 [33, 34] 进行微调。

3.6 在线部署

部署以高效的特征存储和异步缓存存储为中心，确保客户查询和模型响应的简化处理和经济高效的管理。

3.6.1 部署策略。部署管理：Sage-Maker [11]⁵用于刷新 COSMO-LM 模型，通过强大的自动化促进客户行为会话日志的动态摄取和高效的模型更新。特征存储集成：此存储对于将模型响应传输到结构化特征至关重要，使其可用于下游应用程序。它处理产品键值对、语义子类别表示和强意图检测等功能。异步缓存存储：用于管理频繁搜索

⁵亚马逊机器学习模型服务<https://aws.amazon.com/pm/sagemaker/>

为了适应日常流量模式，该商店通过两层缓存策略，结合预加载的年度频繁搜索和批量处理的日常请求，有效捕获用户查询。

3.6.2 操作流程。我们列出了如图 5 所示的关键流程：

- **模型部署：**COSMO-LM部署在SageMaker上，用于处理用户行为会话日志和动态模型更新。
- **请求处理：**针对异步缓存存储进行初始查询检查，快速检索频繁查询的响应或转发其他查询以进行批处理。
- **批处理和缓存更新：**特征存储用于-mats 语言模型响应结构化洞察，更新缓存以供将来查询。
- **与下游应用程序的通信：**来自缓存的结构化数据增强了各种下游应用程序，提供了丰富的功能以改进用户交互。
- **反馈循环：**通过将用户交互反馈到 COSMO-LM 中来实现持续的模型细化，确保最新的确定对不断变化的用户行为的响应能力。

3.6.3 影响和限制。COSMO-LM 的部署利用异步缓存存储和特征存储策略，有效满足 Amazon 有限的搜索延迟要求，同时保持与大多数流量的实时服务相当的存储成本。这种方法显着增强了我们快速、经济地管理在线请求的能力。需要承认的是，即使我们每天更新模型，我们在处理实时信息（例如限时抢购）方面仍然受到限制。这些时间敏感的事件通常在短时间内波动，对我们当前系统快速吸收和反映此类即时变化的能力提出了挑战。这一限制强调了进一步开发的必要性，以增强我们的系统响应电子商务活动快节奏动态的敏捷性。

4 评估和应用

在本节中，我们采用指令调整的 COSMO 语言模型来为下游应用程序生成电子商务常识知识，即搜索相关性、基于会话的推荐和搜索导航。我们进行了广泛的离线和在线评估实验，以证明我们提出的框架和部署系统的有效性。

4.1 搜索相关性

确定搜索查询和文档之间的相关性分数是信息检索的核心，它是搜索引擎的重要组成部分[29]。电子商务产品搜索的一个主要挑战是查询和产品目录之间的语义差距 [10, 17]。其中一些需要丰富的常识知识才能将它们联系在一起。例如，查询“冬天的衣服”通常暗示用户想要衣服保暖。因此，我们利用解释搜索购买行为的 COSMO 知识来增强搜索相关性预测。




图 6：搜索相关性模型的图示。

表5：不同地区（市场）ESCI评估数据集统计。

	KDD杯	我们	ca	英国	在
# 训练对	1,393,063	1,148,528	220,114	462,560	1,480,116
# 测试对	425,762	383,695	72,500	155,138	495,078
# 精确对	1,247,558	1,104,417	245,796	455,947	1,352,128
# 唯一查询	97,345	57,971	9,537	32,162	42,884
# 独特的产品	1,215,851	803,363	136,398	427,572	456,407

形式上，给定查询 $Q = \{q_1, q_2, \dots, q_n\}$ 和检索到的产品列表 D ，其中 $P \in D$ ，排名或分类任务都需要每个查询-产品对的相关性得分 $\{Q, P\}$ [21]。在真实的电子商务系统中，每个产品都附有辅助信息，例如产品标题、描述和属性。简单来说，我们将它们连接成一个文本范围 $P = \{p_1, p_2, \dots, p_m\}$ 。如前所述，查询 Q 和产品信息 P 中的用户意图之间仍然存在语义差距，我们利用 COSMO-LM 生成查询-产品对背后的常识知识 $G = \{g_1, g_2, \dots, g_l\}$ 并显式增强他们的联系。

4.1.1 实验设置。我们采用 KDD Cup 2022 公开发布的亚马逊购物查询数据集⁶。按照任务 2 的设置，测量搜索相关性的问题被表述为四类分类问题：将给定产品区分为 Exact 用户查询的替换、补充或不相关匹配。为了验证我们方法的通用性，我们还从我们的在线系统收集了类似的数据集，以适应不同市场（即美国（us）、加拿大（ca）、英国（uk）和印度（in））。数据集统计数据如表 5 所示。考虑到类别不平衡分布，我们报告了 Macro F1 和 Micro F1，但更关注前一个。

- 4.1.2 基线。我们考虑两种代表性架构作为基线，如图 6 所示：
- 双编码器[22, 28]，也称为双塔模型，将查询表示和产品标题表示的串联作为多层感知器的输入来预测相关性标签。
 - 交叉编码器[42]将所有相关特征（例如查询、产品标题、描述等）输入到统一编码器中，并利用联合表示进行预测。

⁶ <https://github.com/amazon-science/esci-data>

表6: 公共ESCI英语子集的实验结果。

方法	固定编码器 宏 F1 微 F1		可训练编码器 宏 F1 微 F1	
双编码器	25.52	65.49	47.96	70.23
交叉编码器 [42]	28.44	66.84	57.49	74.23
带意图的交叉编码器	45.52	86.40	73.48	90.78
Δ	60.06%	29.26%	27.81%	22.30%

由于额外的注意力交互, 交叉编码器模型通常优于双编码器模型。因此, 我们用生成的知识特征来增强交叉编码器模型, 即连接 $[Q, P, G]$ 作为输入。我们按照[42]使用强大的 deberta-v3-large⁷作为基本模型, 并考虑编码器的固定和调整设置。

4.1.3 公共数据集结果。表 6 显示, COSMO-LM 生成的知识捕获隐式电子商务常识, 可以显著提高查询产品语义相关性的性能。当编码器固定时, 两种架构之间没有太大差异。但增强意图知识使 Marco F1 的性能提高了约 60%, Micro F1 的性能提高了 30%。当编码器的参数更新时, 我们仍然可以观察到性能提升了 25% 左右。最后, 生成的知识帮助交叉编码器实现了 73.48% Macro F1 和 90.78% Micro F1, 甚至超越了 KDD Cup 排行榜的 top-1 集成模型 [42]。

4.1.4


4.1.5 私有数据集结果。为了进一步验证我们的方法在多区域场景下的有效性, 我们在大规模私有数据集上进行了类似的实验。不同地区(市场)的产品分布和查询语言习惯可能存在显著差异。我们期望我们生成的知识可以为搜索相关系统提供高质量的特征或信号, 并推广到更复杂的场景。从图7a

和图7b, 我们可以得出以下观察结果: 1)。即使注释有限, 我们的 COSMO-LM 也始终可以帮助增强跨编码器性能, 这与第 4.1.3 节中公共数据集的结果一致。2)。当编码器固定或调整时, 意图增强的交叉编码器模型可以显著优于所有语言环境的基线方法。在在线部署环境中, 生成的知识以及存储在特征存储中的其他特征被集成以做出最终预测, 如图5所示。为了提高服务效率, 我们为频繁的搜索查询预先缓存特征。


4.2 基于会话的推荐

推荐系统已经成为最重要的组成部分之一

电子商务平台上的产品供客户选择海量且快速增加的产品。除了用户配置文件之外, 一段时间内与多个用户-项目交互相关的会话可以更好地捕获用户偏好和意图[36]。基于会话的推荐通常会预测下次点击或购买



(a) 宏F1



(b) 微F1

图 7: 四个不同地区的私有 ESCI 数据集的比较结果。

给定匿名行为序列 $S = \{v_1^s, v_2^s, \dots, v_n^s\}$, 产品项集中的项 $V = \{v_1, v_2, \dots, v_m\}$ 按时间顺序排列, 是会话的长度 S

例如 RNN [7]、transformers [31], 用于捕获会话中的用户动态偏好。进一步的项目序列可以组织为会话图 $G_s = (V_s, E_s)$, 使用图神经网络对相邻项目的复杂的成对交互进行建模。边的关系 (v_i, v_j) 可以通过交互方向来定义, 即入边或出边[39]。顺序方法或基于图形的方法都只学习 v_i 的项目嵌入, 但忽略产品的辅助信息, 例如产品标题、产品属性和交互模式。其中, 与点击/购买行为相关的搜索查询有助于更好地捕获用户意图和不断变化的偏好变化。因此, 我们通过辅助用户搜索关键字序列 $K = \{k^s, k^s, \dots, k^s\}$ 以及我们生成的知识来改进基于会话的推荐

每个 $1 \ 2$ 搜索产品对 (v_i^s, k_i^s) 。

4.2.1 实验设置。我们从日志系统中收集并过滤一周的会话数据, 这些数据属于服装和电子产品类别。每个会话限制在 20 分钟内, 包含同一域中的高频商品, 并以成功购买结束。对于训练/测试分割, 前五天的会话用作训练, 而第六天和最后一天的会话用作训练

⁷ <https://huggingface.co/microsoft/deberta-v3-large>

表7：两类基于Session的推荐数据集统计。“平均。赛斯。L。”代表平均会话长度。“平均。Q.L”是平均查询长度。“平均唯一性。Q.L”代表平均唯一查询长度。

	衣服			电子产品		
	火车	开发者测试		火车	开发者测试	
# 会话	1.32M	0.24M	0.23M	3.13M	0.59M	0.58M
平均。赛斯。L。	8.79	8.78	8.70	12.27	12.17	12.22
平均。Q.L.	8.32	8.29	8.22	11.68	11.61	11.61
平均唯一性。Q.L.	1.36	1.37	1.36	2.47	2.48	2.48

天被用作验证和测试数据。数据集统计数据详见表 7。电子领域的会话具有比服装更长的唯一查询序列。这表明用户可能会修改他们原来的搜索关键词，对用户查询的动态建模可以帮助精确预测用户行为。我们制定

像之前的工作[36]一样，将基于会话的推荐作为排名问题，并在我们的实验中采用常用的指标，即 Hits@10、NDCG@10 和 MRR@10，

4.2.2 基线。我们与竞争性顺序模型和基于图的模型作为基线进行比较：

- FPMC [23]通过基于马尔可夫链的方法制定会话的表示。
- GRU4Rec [7] 利用门控循环单元（GRU）来模拟马尔可夫决策过程，但具有更好的泛化能力。
- STAMP [12] 将注意力集中在最后一项和之前的历史记录上，以代表用户的短期兴趣。
- CSRM [35]结合了内部存储器编码器和外部存储器来捕获会话相关性。
- SR-GNN [43] 是第一个将图神经网络（GNN）应用于 SBR 任务，它将会话序列转换为直接的未加权图来学习项目和转换表示。
- GC-SAN [44]通过图卷积后对整个图进行自注意力来扩展 SR-GNN，以获得全局表示。
- GCE-GNN [39] 通过软关注聚合了会话图和全局图的两个级别的项目嵌入。

4.2.3 COSMO-GNN。初步实验表明，GCE-GNN 可以在各种基于会话的推荐数据集上实现强大的性能，并通过两级 GNN 学习更好的项目嵌入。因此，我们用 COSMO-LM 生成的搜索查询相关知识扩展 GCE-GNN，并联合优化 GNN 以实现搜索意图感知推荐。我们将我们提出的方法命名为 COSMO-GNN。正式来说，对于会话 S 中的时间步 t ，用户搜索查询 k^s 并与项目 v^s 进行交互。从 GCE-GNN 获得的项目嵌入表示为 h^s_t ，然后 COSMO-LM 用于使用高级分析和客户行为生成意图 i^s_t 。使用查询-产品对解释行为的知识 (v_t, k_t) 。我们利用相同的 LM 对生成的知识进行向量化并获得嵌入 g^s_t 的会话知识。为了将知识空间与 GNN 特征空间对齐，使用两层感知器将知识表示 g^s 转换为 $\tilde{g}^s$ 。最终的代表见解，涵盖了广泛的用户意图，而每个步骤的tation是GNN项嵌入的串联

表 8：基于会话的建议的实验结果。

方法	衣服			电子产品		
	点击率@10	NDCG@10	MRR@10	点击率@10	NDCG@10	MRR@10
FPMC 系列	62.16	45.07	39.60	21.79	16.01	14.18
格鲁4雷克	83.20	63.37	56.94	49.53	33.99	29.06
邮票	81.34	61.32	54.86	56.96	38.74	32.92
CSRM	82.31	65.59	60.25	61.66	46.63	41.83
SRG神经网络	85.82	69.68	64.45	67.83	55.23	51.22
GC-SAN 系列	84.43	68.96	63.93	66.88	55.87	52.34
GCE-GNN 系列	86.67	69.35	63.79	70.13	55.17	50.37
科斯莫-GNN	90.18	72.30	67.08	74.21	56.26	50.67
Δ	4.05%	3.76%	4.08%	5.82%	0.70%	-3.19%

和知识嵌入，即 $[h^s, g^s]$ 。继[39]之后，会议

可以通过对所有步骤的表示进行平均轮询来获得表示。

4.2.4 结果。实验结果如表8所示。我们可以观察到： 1). 我们提出的 COSMO-GNN 在两个领域的 Hits@10 和 NDCG@10 上显着优于所有竞争基线，并且几乎与 MRR@10 竞争所有基线。 2)。 COSMOGNN 在具有更复杂和多样化搜索序列的会话数据上取得了稍微更大的改进（5.82% vs. 4.05% Hits@10）。如表 7 所示，电子产品会话中涉及的独特搜索查询多于服装会话（2.47 比 1.36）。原因可能是用户对服装的意图更容易描述，但需要更多的背景知识来修改才能达到用户真正需要的。更多研究（例如 COSMO 如何减少查询重写）留待将来的工作。

4.3 搜索导航

除了上述传统的电子商务场景之外，COSMO 还可以彻底改变搜索导航，从传统的以产品为中心的分类法转向以客户为中心的方法。这种转变增强了购物体验，使其与客户的意图和行为更加紧密地结合，并通过动态提供具有客户查询概念的分类法来弥合产品分类和客户语言之间的差距。具体来说，COSMO意图知识可以进一步组织成如图8所示的层次结构，将粗粒度的知识（露营）扩展到细粒度的知识（冬季露营），并且意图概念进一步与诸如冬靴之类的产品概念相关联。

4.3.1 多转弯导航。COSMO 以其多层动态导航系统而著称（图 9）。

(1) 广义概念解释：首先要解决

泛的查询

无需明确的领域知识。

(2) 产品类型和子类型发现：随后，COSMO帮助用户识别具体的产品类型和子类型，擅长处理直接产品和抽象产品

查询。




图 8: COSMO 尾部知识的层次结构图示。



图 9: 使用 COSMO 的搜索导航体验

- (3) 基于属性的细化：最后一层有助于微调搜索结果，允许用户根据特定属性进行过滤，并使结果与个人偏好保持一致。

COSMO 功能的核心是多转弯导航。在这里，COSMO 擅长通过持续推荐提供多轮搜索细化。例如，搜索“露营”可能会导致选择“充气床垫”，然后细化为“露营充气床垫”。COSMO 将针对湖边露营、山地露营、4人露营等不同需求，推出各种类型的露营气垫。这种多转弯导航可以实现更深入、更精确的细化，反映自然发现过程并显著增强用户的搜索体验。

4.3.2 在线实验。将 COSMO 集成到我们的在线搜索导航系统中带来了重大的业务改进，凸显了基于 COSMO-LM 的应用程序的强大功能和潜力。这一结论是根据亚马逊精心进行的在线 A/B 测试得出的，该测试总共进行了几个月，目标是亚马逊美国约 10% 的流量。这些结构良好的测试显示，相对增加了 0.7%



图 10: COSMO-LM 生成示例

该细分市场的产品销售，意味着年收入激增数亿美元。此外，在同一交通段内，导航参与率增加了 8%，这凸显了客户互动和满意度的改善。这些结果尤其重要，因为它们源自搜索页面上单个、相对次要的功能的实现，展示室可见性有限，如图 9 所示。这个初始实现的成功表明了一个巨大的机会：通过扩展 COSMO-LM 涵盖所有导航流量，我们预计有可能产生数十亿美元的收入增长。此外，这一充满希望的结果还凸显了在各种其他功能和应用程序中利用 COSMO-LM 的巨大潜力，为增强用户体验和业务增长开辟了新途径。

5 结论与讨论

在本文中，我们提出对电子商务注释数据集（表述为指令）的语言模型进行微调，以生成符合人类偏好的高质量常识知识。为了收集大规模、多样化的指令数据，我们设计了一个基于海量用户行为的自动指令生成管道。扩展产品领域、关系类型和微调任务可实现可扩展的知识提取。此外，下游应用程序，例如语义相关性和基于会话的推荐，证明了从指令微调语言模型生成的知识的有效性。与直接从大型语言模型中提取知识相比，指令微调模型参数较少，在模型推理效率方面具有显著优势。我们的工作代表了将语言模型与特定领域的人类偏好结合起来的的第一步，我们希望自动指令数据管道可以应用于其他领域。

致谢

宋扬秋得到了香港研究资助局的RIF（R6020-19和R6021-20）和GRF（16211520和16205322）的支持。宋扬秋感谢教资会研究部的支持

配套补助金 (RMGS20EG01-D、RMGS20CR11、RMGS20CR12、RMGS20EG19、RMGS20EG21、RMGS23CR05、RMGS23EG08)。

参考文献

- [1] 白云涛、Saurav Kadavath、Sandipan Kundu、Amanda Askell、Jackson Kernion、Andy Jones、Anna Chen、Anna Goldie、Azalia Mirhoseini、Cameron McKinnon 等。2022.宪法人工智能：人工智能反馈的无害性。arXiv 预印本 arXiv:2212.08073 (2022)。
- [2] 汤姆·布朗、本杰明·曼、尼克·莱德、梅兰妮·苏比亚、贾里德·D·卡普兰、普拉富拉·达里瓦尔、阿文德·尼拉坎坦、普拉纳夫·希亚姆、吉里什·萨斯特里、阿曼达·阿斯科尔等。2020 年。语言模型是小样本学习者。NeurIPS (2020), 1877-1901。
- [3] 蒋伟林、李卓涵、林子、盛颖、吴张浩、张浩、郑连民、庄思源、庄永浩、Joseph E. Gonzalez、Ion Stoica 和 Eric P. Xing。2023.Vicuna: 一款开源聊天机器人, 以 90%* ChatGPT 质量给 GPT-4 留下深刻印象。<https://lmsys.org/blog/2023-03-30-vicuna/>
- [4] Hyung Won Chung、Le Hou、Shayne Longpre、Barret Zoph、Yi Tay、William Fedus、Eric Li、Xuezhi Wang、Mostafa Dehghani、Siddhartha Brahma 等。2022.扩展指令微调语言模型。arXiv 预印本 arXiv:2210.11416 (2022)。
- [5] 邓淑敏、王成明、李周波、张宁宇、戴泽林、陈鹤红、熊飞宇、严明、陈强、陈莫莎、陈焦彦、杰夫·Z·潘、Bryan Hooi 和华军陈。2022. BillionScale 预训练多模态业务知识图谱的构建与应用。ArXiv abs/2209.15214 (2022)。
- [6] 何鹏程、刘晓东、高剑锋、陈伟柱。2021.DeBERTa: 具有解缠注意力的解码增强型 BERT。在 ICLR 中。
- [7] Balázs Hidasi、Alexandros Karatzoglou、Linus Baltrunas 和 Domonkos Tikk。2016。基于会话的循环神经网络推荐。在 ICLR 中。
- [8] 李凤林、陈鹤红、徐国海、邱田、季峰、张吉和陈海清。2020. AliMeKG: 领域知识图谱构建及在电子商务中的应用。第 29 届 ACM 国际信息与知识管理会议论文集。2581-2588。
- [9] 李雷、张永峰、陈莉。2020。生成推荐的神经模板解释。在 CIKM 中。755-764。
- [10] 李森、吕福玉、金太伟、李贵阳、郑玉坤、庄涛、刘庆文、曾小毅、郭俊杰和马千里。2022. 淘宝搜索查询重写。第 31 届 ACM 国际信息与知识管理会议论文集。3262-3271。
- [11] Edo Liberty、佐哈尔·卡宁、兵翔、劳伦斯·鲁内尔、巴里斯·科斯基、拉梅什·纳拉帕蒂、胡里奥·德尔加多、阿米尔·萨多吉、尤里·阿斯塔肖诺克、皮亚里·达斯等。2020. 亚马逊 Sagemaker 中的弹性机器学习算法。2020 年 ACM SIGMOD 国际数据管理会议论文集。731-737。
- [12] 刘巧、曾毅夫、Refuoe Mokhosi 和张海滨。2018. STAMP: 基于会话的推荐的短期注意力/内存优先级模型。在 SIGKDD 中。1831-1839。
- [13] 罗旭升、波乐、吴金航、李林、罗志、杨永华、杨克平。2021.AliCoCo2: 常识知识提取、表示及其在电子商务中的应用。在 SIGKDD 中。3385-3393。
- [14] 罗旭升、刘鲁新、杨永华、波乐、曹远鹏、吴景航、李强、杨克平和朱庆强。2020. AliCoCo: 阿里巴巴电商认知概念网。在 SIGMOD 中。313-327。
- [15] Reiichi Nakano、Jacob Hilton、Sucher Balaji、Jeff Wu、Long Ouyang、Christina Kim、Christopher Hesse、Shantanu Jain、Vineet Kosaraju、William Saunders 等。2021.Webgpt: 浏览器辅助问答与人类反馈。arXiv 预印本 arXiv:2112.09332 (2021)。
- [16] 倪建模、李家成和朱利安·麦考利。2019。使用远程标记评论和细粒度方面证明建议的合理性。在 EMNLP 中。188-197。
- [17] Priyanka Nigam、Yiwei Song、Vijai Mohan、Vihan Lakshman、Weitian Ding、Ankit Shingavi、Choon Hui Teo、Hao Gu 和 Bing Yin。2019.语义产品搜索。第 25 届 ACM SIGKDD 国际知识发现与数据挖掘会议论文集。2876-2885。
- [18] 欧阳龙、吴杰夫、徐江、迪奥戈·阿尔梅达、卡罗尔·L·温赖特、帕梅拉·米什金、张冲、桑迪尼·阿加瓦尔、卡塔琳娜·斯拉玛、亚历克斯·雷等。2022. 训练语言模型以遵循人类反馈的指令。arXiv 预印本 arXiv:2203.02155 (2022)。
- [19] 彭宝林、李春园、何鹏程、米歇尔·加利和高剑峰。2023. 使用 gpt-4 进行指令调整。arXiv 预印本 arXiv:2304.03277 (2023)。
- [20] 张银岑、张宁宇、陈辉、戴泽林、徐泽中、王成明、王晓宇、陈强和陈华军。2022.利用电子商务基准数据集进行常识知识显著性评估。arXiv: 2205.10843 (2022)。
- [21] Chandan K. Reddy、Lluís Màrquez、Fran Valero、Nikhil Rao、Hugo Zaragoza、Sambaran Bandyopadhyay、Arnab Biswas、Anlu Xing 和 Karthik Subbian。2022. 购物查询数据集: 用于改进产品搜索的大规模 ESCI 基准。arXiv:2206.06588
- [22] 尼尔斯·雷默斯和伊琳娜·古列维奇。2019.Sentence-BERT: 使用 Siamese BERT 网络的句子嵌入。在 EMNLP-IJCNLP 中。3982-3992。
- [23] 史蒂芬·伦德尔、克里斯托夫·弗罗伊登塔勒和拉尔斯·施密特-蒂姆。2010. 分解个性化马尔可夫链以进行下一个篮子推荐。在万维网。811-820。
- [24] Victor Sanh、Albert Webson、Colin Raffel、Stephen Bach、Lintang Sutawika、Zaid Alyafeai、Antoine Chaffin、Arnaud Stiegler、Teven Scao、Arun Raja 等。2022。多任务提示训练实现零样本任务泛化。在国际学习代表会议上。
- [25] 马丁·萨普、罗南·勒·布拉斯、艾米丽·阿拉维、钱德拉·巴加瓦图拉、尼古拉斯·劳里、汉娜·拉什金、布伦丹·鲁夫、诺亚·A·史密斯和 Yejin Choi。2019. Atomic: 用于 if-then 推理的机器常识图灵。在 AAAI。3027-3035。
- [26] William Saunders、Catherine Yeh、Jeff Wu、Steven Bills、Long Ouyang、Jonathan Ward 和 Jan Leike。2022. 协助人类评估者的自我批评模型。arXiv 预印本 arXiv:2206.05802 (2022)。
- [27] 托比亚斯·施罗德、泰伦斯·C·斯图尔特和保罗·萨加德。2014.意图、情感和行动: 基于语义指针的神经理论。认知科学 38, 5 (2014), 851-880。
- [28] 沉业龙、何晓东、高剑峰、邓力、格雷厄姆·梅尼尔。2014 年。使用卷积神经网络学习网络搜索的语义表示。载于万维网第 23 届国际会议论文集。373-374。
- [29] 阿米特·辛格等人。2001。现代信息检索: 简要概述。IEEE 数据工程。公刊。24, 4 (2001), 35-43。
- [30] 罗宾·斯皮尔、约书亚·钦和凯瑟琳·哈瓦西。2017。Conceptnet 5.5: 开放的多语言常识图。在 AAAI。4444-4451。
- [31] 孙飞、刘军、吴健、裴昌华、林晓、欧文武和姜鹏。2019.BERT4Rec: 使用 Transformer 的双向编码器表示进行顺序推荐。第 28 届 ACM 国际信息和知识管理会议论文集。1441-1450。
- [32] Rohan Taori、Ishaan Gulrajani、张天一、Yann Dubois、李学晨、Carlos 盖斯特林、珀西·梁和 Tatsunori B. Hashimoto。2023. 斯坦福羊驼: 一种遵循指令的 LLaMA 模型。https://github.com/tatsu-lab/stanford_gpt4
- [33] 雨果·图夫龙、蒂博·拉夫里尔、戈蒂埃·伊扎卡尔、泽维尔·马丁内特、玛丽-安妮·拉肖、蒂莫西·拉克鲁瓦、巴蒂斯·罗齐埃、纳曼·戈亚尔、埃里克·汉布罗、费萨尔·阿扎尔等。2023. Llama: 开放高效的基础语言模型。arXiv 预印本 arXiv:2302.13971 (2023)。
- [34] 雨果·图夫龙、路易斯·马丁、凯文·斯通、彼得·艾伯特、阿贾贾德·阿尔马海里、亚斯-我的 Babaee、Nikolay Bashlykov、Soumya Batra、Prajwal Bhargava、Shruti Bhosale 等人。2023. Llama 2: 开放基础和微调的聊天模型。arXiv 预印本 arXiv:2307.09288 (2023)。
- [35] 王梅瑞、任鹏杰、梅雷、陈祝民、马军、Maarten de Rijke。2019。使用并行内存模块的基于会话的协作推荐方法。在西吉尔。345-354。
- [36] 王守进、曹龙兵、王岩、全志胜、Mehmet A Orgun 和 Defu Lian。2021. 基于会话的推荐系统调查。ACM 计算调查 (CSUR) 54, 7 (2021), 1-38。
- [37] 王一中、Yeganeh Kordi、Swaroop Mishra、Alisa Liu、Noah A Smith、Daniel Khashabi 和 Hannaneh Hajishirzi。2022.自我指导: 将语言模型与自我生成的指令结合起来。arXiv 预印本 arXiv:2212.10560 (2022)。
- [38] 王一中、Swaroop Mishra、Pegah Alipoormolabashi、Yeganeh Kordi、Amirreza Mirzaei、Atharva Naik、Arjun Ashok、Arut Selvan Dhanasekaran、Anjana Arunkumar、David Stap、Eshaan Pathak、Giannis Karamanolakis、赖海志、Ishan Purohit、Ishani Mondal、Jacob Anderson、Kirby Kuznia、Krima Doshi、Kuntal Kumar Pal、Maitreya Patel、Mehrad Moradshahi、Mihir Parmar、Mirali Purohit、Neeraj Varshney、Phani Rohitha Kaza、Pulkit Verma、Ravsehaj Singh Puri、Rushang Karia、Savan Doshi、Shailaja Keyur Sampat、Siddhartha Mishra、Sujan Reddy A、Sumanta Patro、Tanay Dixit 和 Xudong Shen。2022. Super-NaturalInstructions: 通过 1600 多个 NLP 任务的声明性指令进行泛化。2022 年自然语言处理经验方法会议论文集。计算语言学协会, 阿拉伯联合酋长国阿布扎比, 5085-5109。<https://aclanthology.org/2022.emnlp-main.340>
- [39] 王紫阳、魏伟、高聪、李晓莉、毛贤灵、邱明辉。2020。用于基于会话的推荐的全局上下文增强图神经网络。在西吉尔。169-178。
- [40] Jason Wei、Maarten Bosma、Vincenzo Zhao、Kelvin Guu、Adams Wei Yu、Brian Lester、Nan Du、Andrew M Dai 和 Quoc V Le。2021 年。经过微调的语言模型是零样本学习者。在 ICLR 中。
- [41] Peter West、Chandra Bhagavatula、Jack Hessel、Jena Hwang、Liwei Jiang、Ronan Le Bras、Ximing Lu、Sean Welleck 和 Yejin Choi。2022.符号知识蒸馏: 从通用语言模型到常识模型。在 NAACL 中。4602-4625。
- [42] 吴凡友、刘洋、Rado Gazo、Benes Bedrich 和曲晓波。2022.提高电子商务搜索结果的一些实践。arXiv 预印本 arXiv:2208.00108 (2022)。



图11：数据标注界面截图。

[43] 吴树、唐雨媛、朱艳桥、王亮、谢兴、谭铁牛。 2019。基于会话的图神经网络推荐。在AAAI。 346-353。

[44] 徐乘风、赵鹏鹏、刘彦池、盛胜、徐家杰、庄富珍、方俊华和周晓芳。 2019。用于基于会话的推荐的图上下文文化 SelfAttention 网络。在 IJCAI 中。 3940-3946。

[45] 于昌龙、王伟奇、刘鑫、白家鑫、宋阳秋、李正、高一凡、曹天宇和尹冰。 2023。FolkScope: 发现电子商务常识的意图知识图谱构建。计算语言学协会的调查结果: ACL 2023。

[46] 纳赛尔·扎尔穆特、张晨伟、李贤、梁彦和东辛鲁纳。 2021。构建产品知识图谱所需了解的一切。在 SIGKDD 中。 4090-4091。

[47] 张宁宇, 贾强怀, 邓淑敏, 邓翔, 叶宏斌, 陈辉, 头怀小, 黄刚, 王赵, 华能伟, 等。 2021。Alicg: 阿里巴巴语义搜索的细粒度和可进化概念图构建。在 SIGKDD 中。 3895-3905。

[48] Susan 张、Stephen Roller、Naman Goyal、Mikel Artetxe、Moya Chen、Shuohui Chen、Christopher Dewan、Mona Diab、Xian Li、Xi Victoria Lin 等。 2022。Opt: 开放预训练的 Transformer 语言模型。 arXiv: 2205.01068 (2022)。

A 知识生成

我们在表 9 中提供了每个类别的生成示例。

表 9：不同类别的世代示例。

类别	例子
服装、鞋履和珠宝 运动与户外	用于骑自行车 能够提供用于削土豆皮的拱形支撑
家居和厨房庭院、草坪和花园	能够在后院闲逛，用来磨剪刀 用于婚礼派对
工具和家居装修 乐器 工业与科学 汽车	能够承受很大的重量，能够挖洞。 用于防止起水泡
电子婴儿用品	能够保持婴儿脚部干燥用于压印织
艺术、工艺品和缝纫	物
纫 健康和家用玩具和游戏	能够给皮肤补水 能够在空中 飞翔 用于保护耳机 用于制作
电子游戏	薯片
杂货和美食办公产品	用于记录遛狗时使用的重要信息
宠物用品其	能够追踪消耗卡路里的
他	

B 知识注释

数据标注的说明概括为五个方面：

- **完整性：**解释必须是一个完整、有意义的句子。
- **相关性：**解释应该与其所指的产品相关，即在含义上密切相关。
- **信息性：**请记住，每个解释都描述了客户的购物行为，因此，它还应该根据产品的功能要求指定用户可能正在寻找什么。
- **合理性：**解释应该在查询确定的特定上下文中以准确、合理和适当的方式描述用户的购物行为。
- **典型性：**尽管我们可能对客户的购物意图有同样有效的推论，但考虑到对所查询产品的了解，这些陈述可以根据它们对典型用户购物行为的代表性进行不同的排名。